XML

Décrire et échanger des données, expliqué simplement

1. C'est quoi le XML ?

XML signifie *eXtensible Markup Language* (langage de balisage extensible). C'est un format de fichier texte qui sert à **stocker et échanger des données** de façon organisée. Contrairement au HTML, on **invente ses propres balises** pour décrire ses données. Un fichier XML est lisible à la fois par un humain et par un programme.

> **Analogie :** un classeur avec des étiquettes. Chaque information est rangée dans une étiquette bien nommée (`<titre>`, `<auteur>`...), et on peut imbriquer des étiquettes les unes dans les autres comme des dossiers et des sous-dossiers.

2. XML et HTML : la différence

	HTML	XML
Rôle	**Afficher** des informations	**Décrire et transporter** des données
Balises	Prédéfinies (`<p>`, `<h1>`...)	Choisies librement (`<livre>`, `<prix>`...)
Rigueur	Tolérant avec les erreurs	**Strict** : une erreur rend le fichier invalide
Affichage	Le navigateur met en forme	Aucune mise en forme : ce sont juste des données

3. Un exemple

```
<?xml version="1.0" encoding="UTF-8"?>
<bibliotheque>
  <livre id="1">
    <titre>Le Petit Prince</titre>
    <auteur>Antoine de Saint-Exupéry</auteur>
    <annee>1943</annee>
  </livre>
  <livre id="2">
    <titre>Germinal</titre>
    <auteur>Émile Zola</auteur>
    <annee>1885</annee>
  </livre>
</bibliotheque>
```

Terme	Définition	Dans l'exemple
Prologue	Première ligne : version et encodage	`<?xml version="1.0" ...?>`
Élément	Une balise ouvrante + son contenu + sa balise fermante	`<titre>Germinal</titre>`
Élément racine	L'élément qui contient tous les autres (**un seul**)	`<bibliotheque>`
Attribut	Information placée dans la balise ouvrante	`id="1"`
Enfant / parent	Un élément à l'intérieur d'un autre	`<titre>` est enfant de `<livre>`

On peut représenter ce fichier comme un **arbre** : `bibliotheque` est le tronc, les `livre` sont les branches, et `titre`, `auteur`, `annee` sont les feuilles.

4. Les règles d'un XML « bien formé »

Un fichier XML doit respecter ces règles pour être valide, sinon un programme refusera de le lire :

- **Un seul élément racine** qui contient tout.
- **Toute balise ouverte doit être fermée** (`<nom>...</nom>`, ou `<vide/>` si elle est vide).
- Les balises doivent être **bien imbriquées** (on ferme dans l'ordre inverse de l'ouverture).
- XML est **sensible à la casse** : `<Nom>` et `<nom>` sont deux balises différentes.
- Les valeurs d'attributs sont **toujours entre guillemets**.
- Les noms de balises ne contiennent pas d'espace et ne commencent pas par un chiffre.

```
<!-- INCORRECT -->
<livre>
  <titre>Germinal
  <auteur>Zola</auteur></titre>      <!-- mauvaise imbrication, balise non fermée -->
</livre>

<!-- CORRECT -->
<livre>
  <titre>Germinal</titre>
  <auteur>Zola</auteur>
</livre>
```

5. Caractères spéciaux et commentaires

Certains caractères ont un sens en XML. Pour les écrire dans le texte, on utilise des **entités** :

Caractère	Entité
<	`<`
>	`>`
&	`&`
"	`"`
'	`'`

Les **commentaires** s'écrivent entre `<!--` et `-->` et sont ignorés par les programmes :

```
<!-- Ceci est un commentaire -->
```

6. Élément ou attribut ?

Une même donnée peut s'écrire de deux façons. En général, on met la donnée principale dans un **élément** et les informations secondaires (identifiant...) dans un **attribut**.

```
<!-- avec un attribut -->
<livre annee="1943">Le Petit Prince</livre>

<!-- avec un élément -->
<livre>
  <titre>Le Petit Prince</titre>
  <annee>1943</annee>
</livre>
```

7. Bien formé ou valide ?

• **Bien formé** : le fichier respecte les règles de syntaxe du XML (voir plus haut).

• **Valide** : il respecte en plus un **modèle** qui décrit quelles balises sont autorisées et dans quel ordre. Ce modèle s'écrit avec une **DTD** ou un schéma **XSD**.

Exemple : un XSD peut imposer que `<annee>` soit un nombre et que chaque `<livre>` ait un `<titre>`.

8. À quoi sert le XML ?

Utilisation	Exemple
Échange de données entre applications	Services web (SOAP), flux d'informations
Fichiers de configuration	`web.config`, `pom.xml` (Java), `AndroidManifest.xml`
Flux de contenu	Flux RSS des sites d'actualité
Images vectorielles	Format SVG
Documents	Les fichiers Word (.docx) et Excel (.xlsx) sont des archives de fichiers XML

Aujourd'hui, le format **JSON** est souvent préféré pour les échanges de données sur le web, car il est plus court. Le XML reste très utilisé pour la configuration et les documents.

9. À retenir

• Le XML sert à **décrire et échanger des données** avec des balises que l'on choisit.

• Il faut **un élément racine**, des balises **fermées** et **bien imbriquées**, et des attributs **entre guillemets**.

• Le XML est **strict** : une erreur de syntaxe rend le fichier inutilisable.

• Le HTML **affiche**, le XML **décrit** des données.

• Une **DTD** ou un **XSD** permet de vérifier qu'un fichier est **valide**.